Atlântico Avanti

CLASSIFICAÇÃO DE RESÍDUOS COM DEEP LEARNING

Defesa de Projeto Final de Machine Learning

Professor: Renê Ripardo
Facilitador: Vinícius Gomes

Squad 2 - Classificação de Resíduos Recicláveis

Alunos:

Ana Marly do Couto da Silva

Anysabele de Paula Barbosa Santos

Elian Ramon de Sarges Rodrigues

Josyele Moura de Alencar

José Yago Lisboa da Silva

João Inácio de Souza Neto

Juliana Leite Pinto Magalhães

SUMÁRIO EXECUTIVO

01 Introdução e Motivação

02 Metodologia: Dataset

03 Arquitetura do Modelo

04 Processo de Treinamento

05 Avaliação de Resultados

06 Conclusões e Resumo

INTRODUÇÃO E MOTIVAÇÃO

[CONTEXTO]

A gestão eficiente de resíduos é um dos maiores desafios urbanos contemporâneos, impactando diretamente a sustentabilidade ambiental.

[PROBLEMA]

A triagem manual de materiais recicláveis é lenta, custosa e altamente suscetível a erros humanos, limitando a escala da reciclagem.

[SOLUÇÃO]

Automação do processo de classificação utilizando Redes Neurais Convolucionais (CNNs) para garantir precisão e escalabilidade.

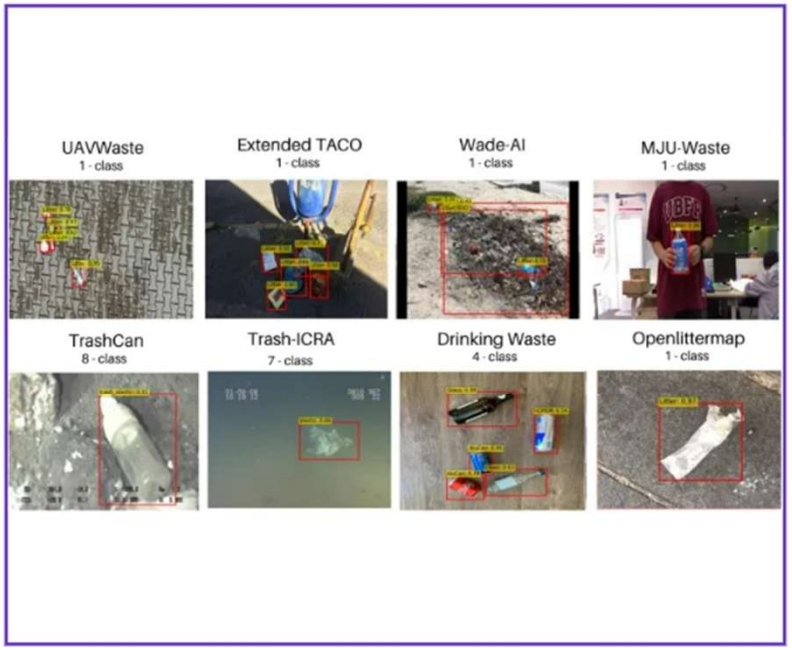

PREPARAÇÃO E CURADORIA DO DATASET

[SELEÇÃO E LIMPEZA]

Foco nas 10 classes com maior volume de dados. Remoção rigorosa de duplicatas para evitar viés e garantir a integridade do aprendizado.

[ESTATÍSTICAS DO DATASET]

Total de imagens após curadoria: **3.855**

Conjunto	Proporção	Quantidade
Treino	70%	2.698
Validação	15%	578
Teste	15%	579

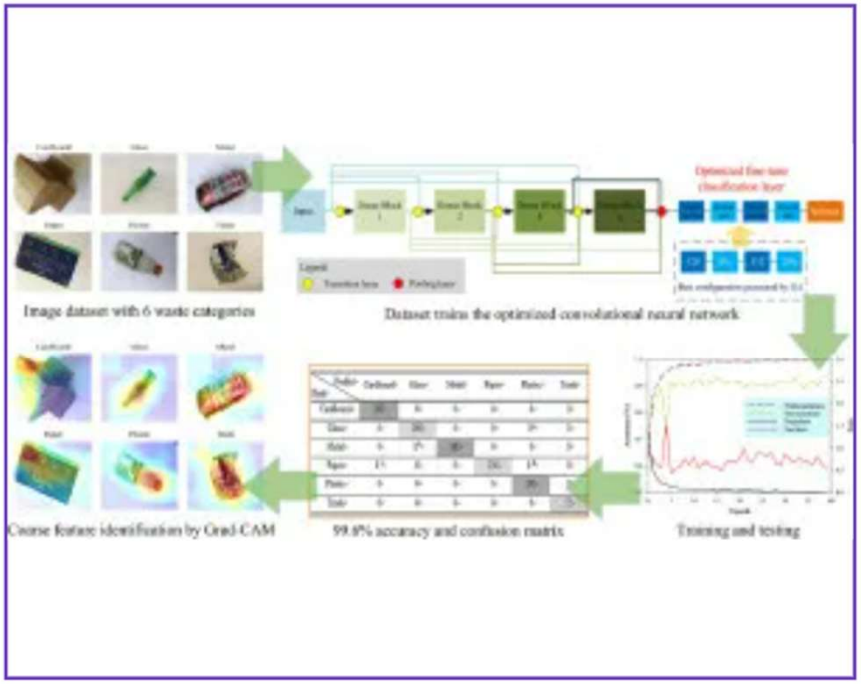

ESTRATÉGIAS DE DATA AUGMENTATION

CONJUNTO DE TREINAMENTO

- Aumento da variabilidade para redução de overfitting.
- Transformações: Rotação, Deslocamento e Inversão Horizontal.

Implementação: ImageDataGenerator (Keras)

VALIDAÇÃO E TESTE

- Manutenção da integridade dos dados originais.
- Aplicação exclusiva da função de pré-processamento nativa.

Função: resnet50.preprocess_input

ARQUITETURA: TRANSFER LEARNING

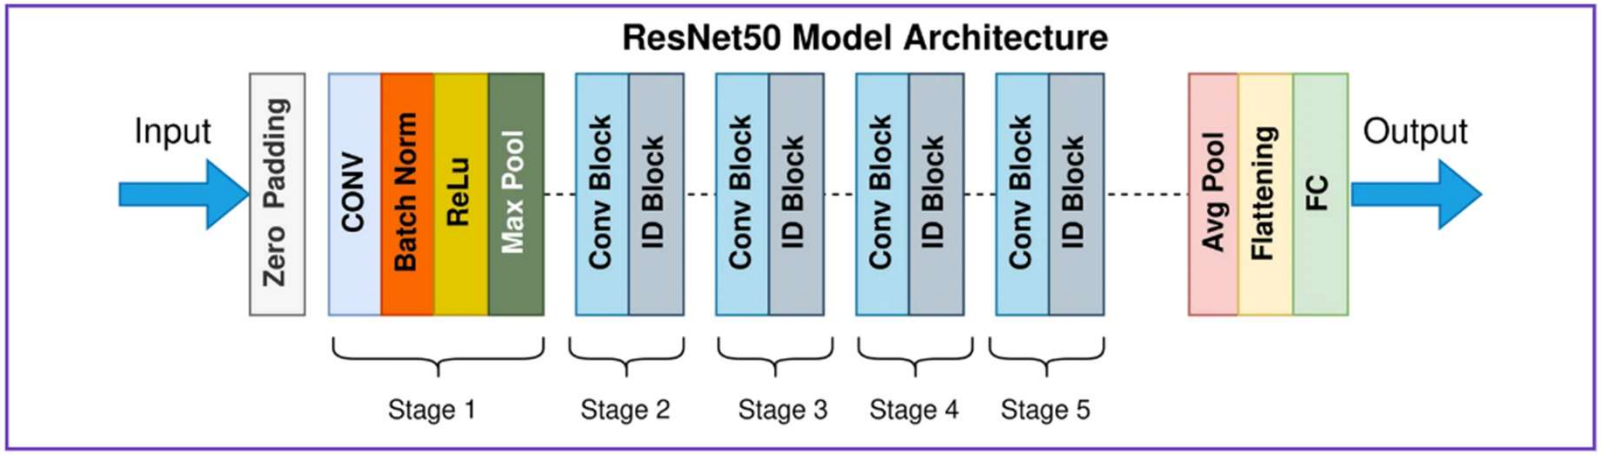

BASE MODEL

Utilização da **ResNet50** pré-treinada no dataset ImageNet como extrator de características.

ESTRATÉGIA

Camadas convolucionais congeladas via `trainable = False` para acelerar a convergência.

CUSTOM HEAD

Inclusão de `GlobalAveragePooling2D` e camadas `Dense` para classificação final.

CONFIGURAÇÃO DO EXPERIMENTO

OTIMIZADOR

Adam

Adaptive Moment Estimation para convergência eficiente.

TAXA DE APRENDIZADO

0.001

Valor padrão otimizado para Transfer Learning.

FUNÇÃO DE PERDA

Categorical Crossentropy

Minimização da divergência em múltiplas classes.

MÉTRICA DE AVALIAÇÃO

Accuracy

Monitoramento da precisão global do modelo.

REPRODUTIBILIDADE

random_state = 42

Garantia de consistência em todas as divisões e inicializações.

DINÂMICA DO PROCESSO DE TREINAMENTO

PROTOCOLO

Planejamento de **5 épocas** para ajuste das camadas superiores via Transfer Learning.

MECANISMO DE CONTROLE

Uso de **Early Stopping** com paciência de 2 épocas para evitar overfitting.

MONITORAMENTO

Foco na minimização da **val_loss** como critério principal de otimização.

CONVERGÊNCIA

Melhor desempenho alcançado na **Época 3**, demonstrando alta eficiência.

AVALIAÇÃO DE DESEMPENHO E RESULTADOS

[ACURÁCIA PONDERADA]

87%

Desempenho no conjunto de teste

Alta capacidade de generalização em todas as 10 classes avaliadas.

[DESTAQUES POR CLASSE]

CLASSE DE RESÍDUO	F1-SCORE
Plastic Water Bottles	0.96
Shoes	0.94
Média Geral	0.87

AVALIAÇÃO DE DESEMPENHO E RESULTADOS

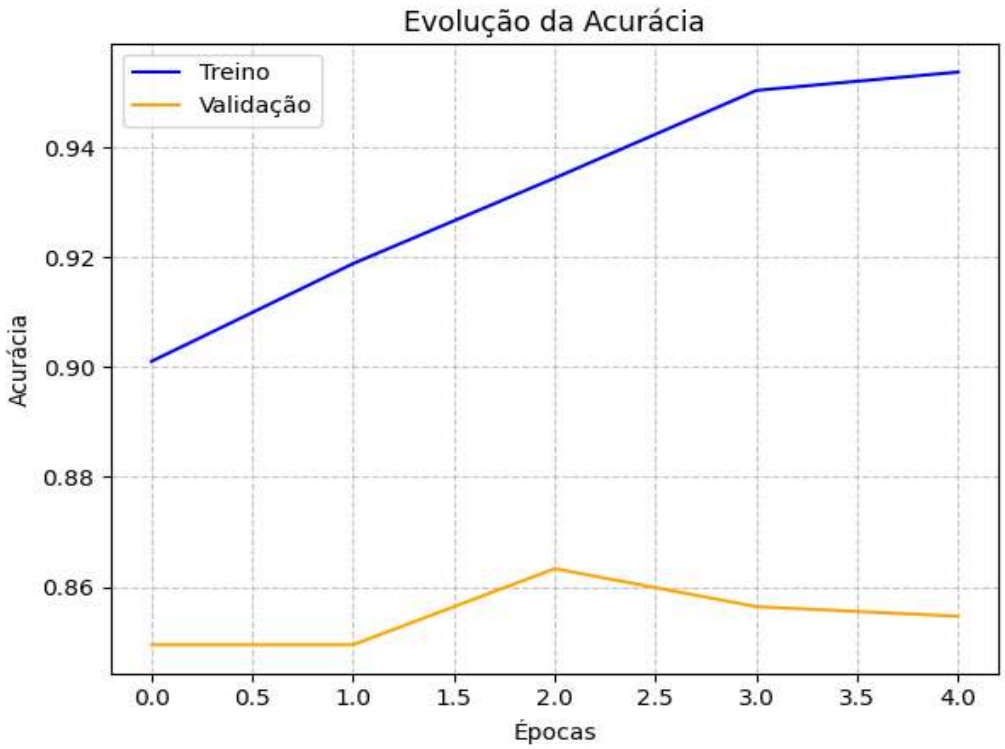

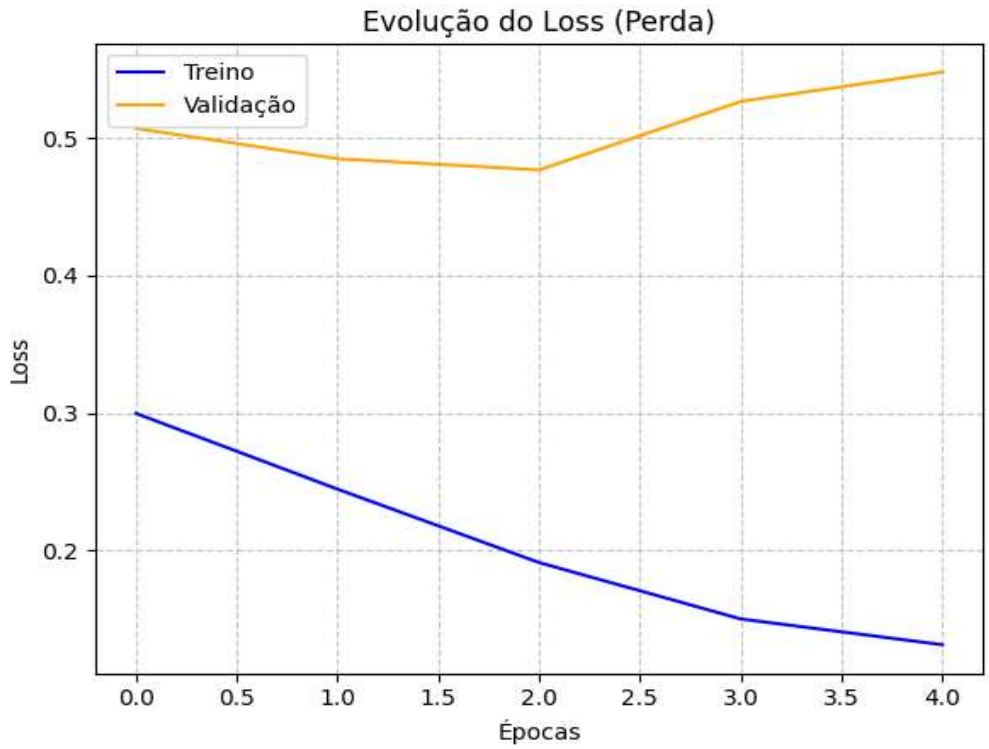

AVALIAÇÃO DE DESEMPENHO E RESULTADOS

```
--- Relatório de Classificação ---
                      precision    recall  f1-score   support

   aluminum_food_cans       0.81      0.83      0.82        52
   aluminum_soda_cans       0.82      0.80      0.81        51
             clothing       0.89      0.89      0.89        70
            magazines       0.91      0.88      0.90        59
            newspaper       0.83      0.83      0.83        66
         office_paper       0.83      0.79      0.81        61
       plastic_straws       0.84      0.92      0.88        50
plastic_water_bottles       0.98      0.94      0.96        51
                shoes       0.92      0.96      0.94        68
             tea_bags       0.90      0.88      0.89        51

             accuracy                           0.87       579
            macro avg       0.87      0.87      0.87       579
         weighted avg       0.87      0.87      0.87       579

CPU times: user 1h 24min 5s, sys: 5min 28s, total: 1h 29min 33s
Wall time: 53min 17s
```

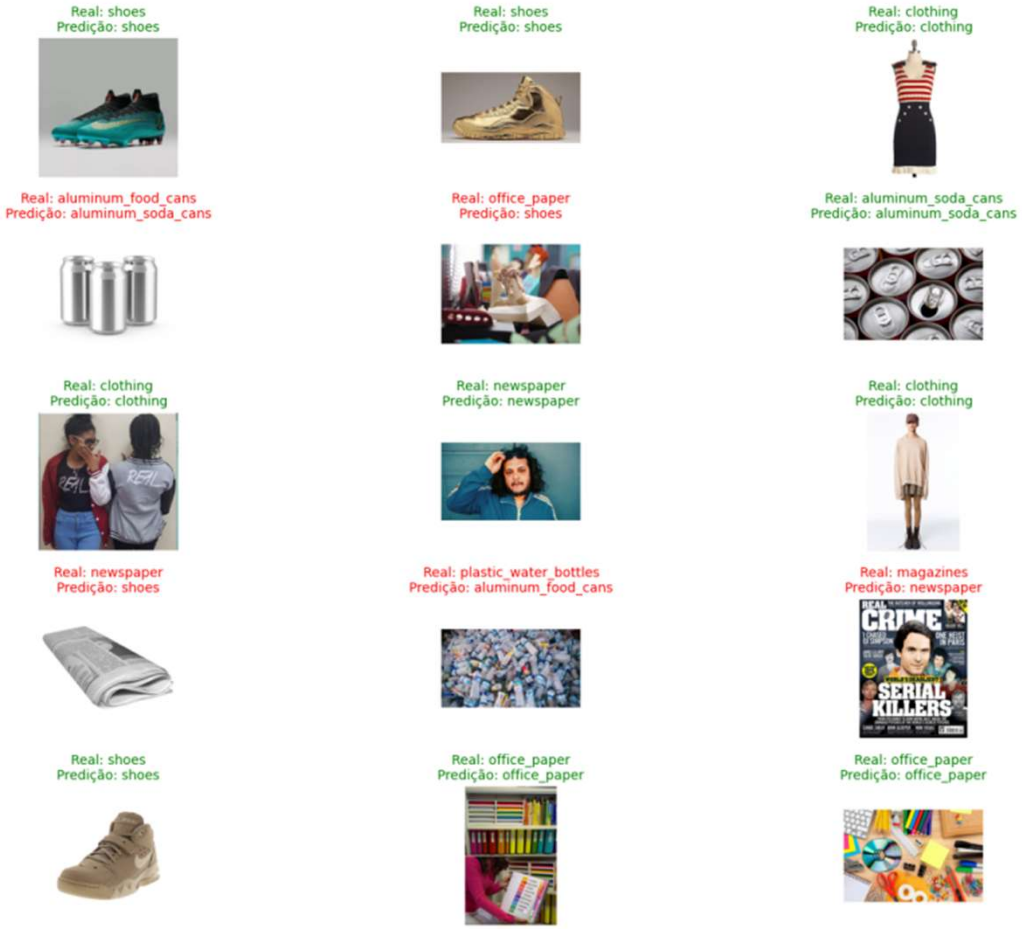

PRINCIPAIS CONTRIBUIÇÕES DO ESTUDO

QUALIDADE DE DADOS

A **limpeza rigorosa** e remoção de duplicatas são críticas para a performance e generalização do modelo.

EFICIÊNCIA COMPUTACIONAL

Uso eficaz de **Transfer Learning** para obter resultados de estado da arte com recursos reduzidos.

IMPACTO SOCIAL

Fornecimento de uma **base tecnológica robusta** para sistemas inteligentes de gestão de resíduos.

CONCLUSÕES E TRABALHOS FUTUROS

Síntese Final

- ResNet50 demonstrou alta robustez na extração de características complexas.
- Acurácia de 87% valida a eficácia do Transfer Learning no domínio.
- Curadoria de dados foi fundamental para garantir a generalização.

Evoluções

- Implementação de Fine-tuning nas camadas convolucionais superiores.
- Uso de técnicas de interpretabilidade (Grad-CAM) para análise visual.
- Desenvolvimento de aplicação mobile em tempo real.

RESUMO FINAL DO TRABALHO

A **limpeza de dados** impacta diretamente o desempenho e a confiabilidade de modelos de Deep Learning.

O **Transfer Learning** permite obter resultados de alta qualidade mesmo com datasets moderados.

O modelo desenvolvido atingiu **87% de acurácia** na classificação automatizada de resíduos recicláveis.

Referências Bibliográficas

- ABADI, M. et al. *TensorFlow: A System for Large-Scale Machine Learning*. OSDI, 2016.
- CHOLLET, F. *Keras: Deep Learning Library for Python*. 2015.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- HE, K.; ZHANG, X.; REN, S.; SUN, J. *Deep Residual Learning for Image Recognition*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.
- RUSSAKOVSKY, O. et al. *ImageNet Large Scale Visual Recognition Challenge*. International Journal of Computer Vision, 2015.
- SHORTEN, C.; KHOSHGOFTAAR, T. *A Survey on Image Data Augmentation for Deep Learning*. Journal of Big Data, 2019.

AGRADECEMOS A ATENÇÃO DE TODOS!

AGRADECIMENTOS

Espaço para Perguntas