FEVEREIRO 2026

Análise de Integridade e Qualidade do Dataset

Classificação de Resíduos Recicláveis

DISCIPLINA

Machine Learning

EQUIPE

Ana Marly do Couto da Silva

Elian Ramon de Sarges Rodrigues

José Yago Lisboa da Silva

Juliana Leite Pinto Magalhães

Anysabele de Paula Barbosa Santos

Josyele Moura de Alencar

João Inácio de Souza Neto

OBJETIVO

Avaliação técnica completa de integridade, consistência, qualidade e preparação para modelagem.

Visão Geral do Dataset

O dataset "Recyclable and Household Waste Classification" contém 15.000 imagens padronizadas para classificação multiclasse.

ESTATÍSTICAS PRINCIPAIS

Total de Imagens	15.000
Número de Classes	30
Resolução	256 × 256 px (Uniforme)
Formato	PNG (100%)
Canais de Cor	3 (RGB)

CATEGORIAS PRINCIPAIS

- Plástico (9 subclasses)
- Vidro (3 subclasses)
- Orgânicos (5 subclasses)
- Papel/Papelão (5 subclasses)
- Metal (4 subclasses)
- Têxteis (2 subclasses)

Estrutura Balanceada: Cada classe possui exatamente 500 imagens, divididas igualmente em 250 'default' (estúdio) e 250 'real_world' (ambiente real).

Integridade dos Arquivos

Verificação de Existência

Total de imagens processadas	15.000
Arquivos não-imagem encontrados	0 ✓
Divergências (listado vs encontrado)	0 ✓
Arquivos com extensão inválida	0 ✓

Padronização de Formato

100%

PADRONIZAÇÃO PNG

Todos os 15.000 arquivos estão no formato PNG, eliminando a necessidade de conversão no pré-processamento.

PNG

Consistência dos Metadados

Análise detalhada das 8 colunas do DataFrame gerado a partir da varredura do diretório.

Coluna	Tipo	Valores Nulos	Status
image_path	String	0	OK
corrupted	Boolean	0	OK
image_hash	Object	0	OK
image_format	String	0	OK
width	Integer	0	OK
height	Integer	0	OK
channels	Integer	0	OK
label	String	0	OK

Dimensões Uniformes

256 LARGURA (PX) × 256 ALTURA (PX) × 3 CANAIS (RGB)

0

VALORES NULOS

Completude total em todos os registros.

Distribuição das Classes

500

IMAGENS POR CLASSE

30

CLASSES TOTAIS

Estrutura Interna:
250 Imagens (Default)
250 Imagens (Real World)

Balanceamento Perfeito

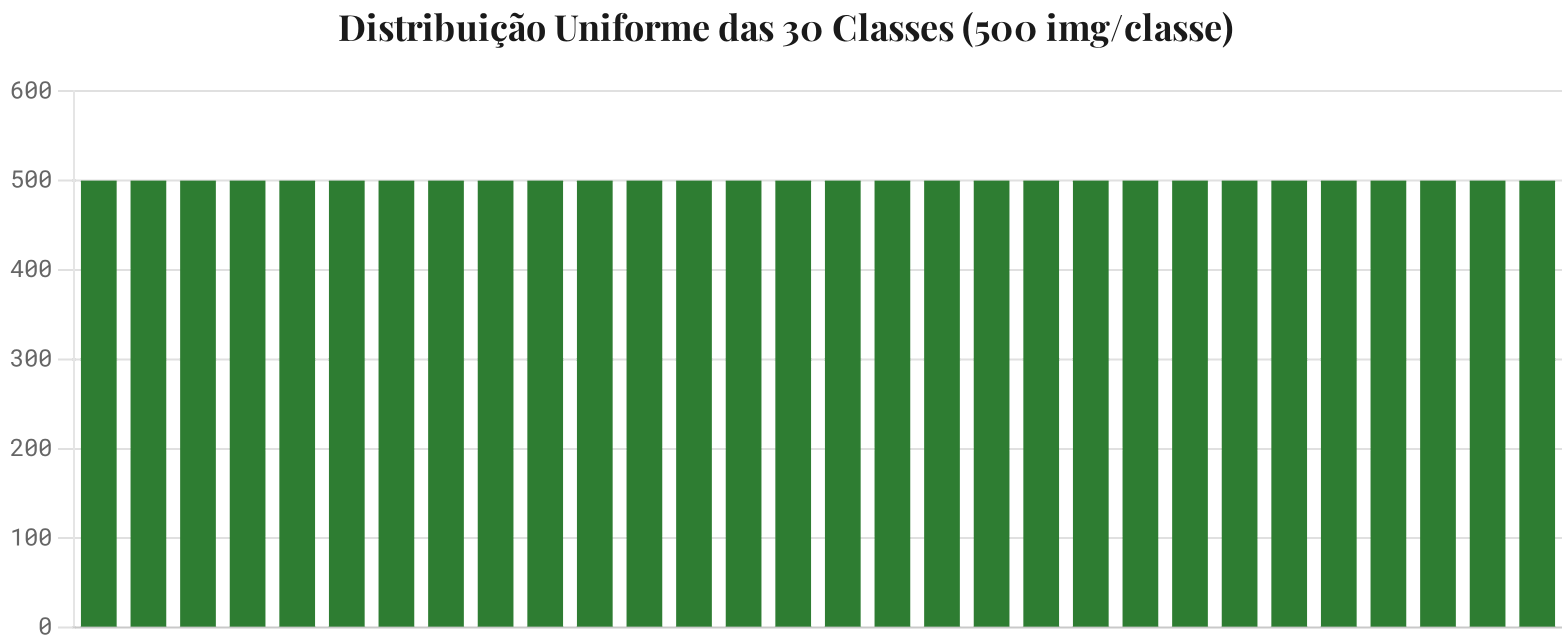

Grupo	Imagens
Plástico (9 classes)	4.500
Papel/Papelão (5 classes)	2.500
Orgânicos (5 classes)	2.500

Grupo	Imagens
Metal (4 classes)	2.000
Vidro (3 classes)	1.500
Têxteis/Outros (4 classes)	2.000

0

IMAGENS CORROMPIDAS

Qualidade das Imagens

METODOLOGIA DE VERIFICAÇÃO

Leitura automatizada de cada arquivo utilizando a biblioteca **OpenCV** (cv2.imread). Falhas de leitura ou retorno 'None' indicariam corrupção.

- **15.000** imagens analisadas
- **100%** de taxa de sucesso na leitura
- Nenhum artefato de compressão severo detectado

```
> Total de Imagens Corrompidas: 0
> Imagens corrompidas: []
```

Identificação de Duplicatas

34,3%

TAXA DE DUPLICAÇÃO

5.149

IMAGENS DUPLICADAS

Identificadas via Hash Perceptual (pHash)

Padrão Identificado

- A maioria das duplicatas ocorre entre as subcategorias **real_world** e **default** da mesma classe.
- Imagens idênticas foram inseridas em ambas as partições de coleta.
- Exemplo: *plastic_detergent_bottles* (Image_171 vs Image_115).

Impacto no Modelo

- **Risco Crítico de Overfitting:** O modelo pode "memorizar" exemplos repetidos.
- **Avaliação Inflada:** Se duplicatas estiverem em treino e teste, a acurácia será artificialmente alta.

AÇÃO NECESSÁRIA: Remoção obrigatória antes da divisão treino/teste.

Principais Achados

Consolidação dos Resultados da Análise

Integridade dos Arquivos
0 divergências, 0 arquivos ausentes
EXCELENTE

Padronização
100% PNG, 256×256 px, RGB
EXCELENTE

Metadados
Completos, sem valores nulos
EXCELENTE

Qualidade Visual
0 imagens corrompidas
EXCELENTE

Balanceamento
500 imagens por classe (Perfeito)
EXCELENTE

Ponto Crítico

34,3%

Taxa de Duplicação

5.149 duplicatas identificadas via hash perceptual.

A maioria ocorre entre as subcategorias *real_world* e *default*.

Impacto: Risco severo de overfitting e métricas de avaliação infladas artificialmente.

Recomendações para Modelagem

5 ações prioritárias para garantir a robustez e confiabilidade do modelo de Machine Learning.

CRÍTICA

Remoção de Duplicatas

Eliminar as 5.149 imagens duplicadas via hash perceptual para evitar overfitting.

ALTA

Divisão Estratificada

Split 70/15/15 mantendo a proporção de classes balanceada.

ALTA

Normalização de Pixels

Escalar valores para [0,1] ou [-1,1] para estabilidade do gradiente.

MÉDIA

Data Augmentation

Rotação, flip e brilho para compensar a redução do dataset após limpeza.

MÉDIA

Verificação de Splits

Garantir que subcategorias 'real_world' e 'default' não vazem entre treino/teste.

Arquiteturas Recomendadas

ResNet-50 | EfficientNet-B0 | MobileNetV3 | Input: 256×256

Conclusão Geral

Apto para Machine Learning

Condição: Após tratamento das duplicatas.

Status por Dimensão:

- ✅ Integridade dos Arquivos
- ✅ Consistência de Metadados
- ✅ Qualidade das Imagens
- ✅ Distribuição de Classes
- ⚠ Duplicatas (Requer Ação)

Recursos

Google Colab
Notebook Equipe 2

Bibliotecas Utilizadas:

pandas | opencv (cv2) | Pillow | imagehash | matplotlib | os

Obrigado!