FEVEREIRO 2026

DISCIPLINA: MACHINE LEARNING

Análise de Integridade e Qualidade do Dataset

Classificação de Resíduos Recicláveis: Tratamento de Duplicatas

EQUIPE

Ana Marly do Couto da Silva
Elian Ramon de Sarges Rodrigues
José Yago Lisboa da Silva
Juliana Leite Pinto Magalhães
Anysabele de Paula Barbosa Santos
Josyele Moura de Alencar
João Inácio de Souza Neto

OBJETIVO

Avaliação técnica completa de integridade, consistência, qualidade e preparação para modelagem, com foco na resolução de duplicatas identificadas.

🎯 INTRODUÇÃO AO PROBLEMA: O DATASET DE RESÍDUOS

Contexto do Dataset

- **Composição:** 15.000 imagens de resíduos recicláveis.
- **Classes:** 30 classes balanceadas (256x256 RGB).
- **Descoberta:** 5.149 imagens duplicadas (34,3% do total).
- **Origem:** Predominantemente entre ambientes de estúdio e mundo real.

Riscos Críticos

- **Overfitting:** Modelo memoriza exemplos, não padrões.
- **Avaliação Inflada:** Métricas de desempenho irrealistas.

> *O problema fundamental não reside na mera existência de imagens duplicadas, mas sim no **vazamento de informação** que ocorre quando essas duplicatas são distribuídas incorretamente entre os conjuntos de treino e teste.*

🧠 IMPACTO EM MODELOS DE VISÃO COMPUTACIONAL: GENERALIZAÇÃO VS. MEMORIZAÇÃO

🧠 O Dilema da Aprendizagem

• **Generalização:** Capacidade de aplicar conhecimento a dados não vistos.

• **Memorização:** Modelo "decora" exemplos de treinamento, sem aprender padrões subjacentes.

☹️ Consequências da Memorização

• **Falsa Confiança:** Métricas de avaliação artificialmente elevadas.

• **Fragilidade em Produção:** Baixa performance em ambientes reais.

🔍 DETECÇÃO DE DUPLICATAS: HASH PERCEPTUAL (PHASH)

Fluxo de Processamento

01
Redução de Tamanho
Redimensionamento para 8x8 ou 32x32 para simplificar a estrutura.

02
Tons de Cinza
Remoção de cor para focar apenas na intensidade luminosa.

03
Cálculo do DCT
Transformada Cosseno Discreta para extrair frequências.

04
Redução de Frequência
Foco nos coeficientes de baixa frequência (características visuais).

05
Cálculo da Média
Média dos valores dos coeficientes selecionados.

06
Geração do Hash
Bits 0 ou 1 baseados na comparação com a média.

Métrica de Decisão

Distância de Hamming

A similaridade é medida pela contagem de bits diferentes entre dois hashes. Diferente do hash criptográfico, pequenas mudanças na imagem resultam em pequenas mudanças no pHash.

LIMIAR TÍPICO: 5-10 BITS

"O pHash permite identificar imagens visualmente idênticas mesmo com variações de compressão ou ruído sutil."

POR QUE NÃO APAGAR TODAS AS DUPLICATAS?

O gráfico abaixo compara a quantidade de imagens por classe antes e depois da remoção das duplicatas. **Apagar todas as duplicatas reduziria drasticamente o volume de dados** em diversas classes, comprometendo a representatividade e o desempenho do modelo.

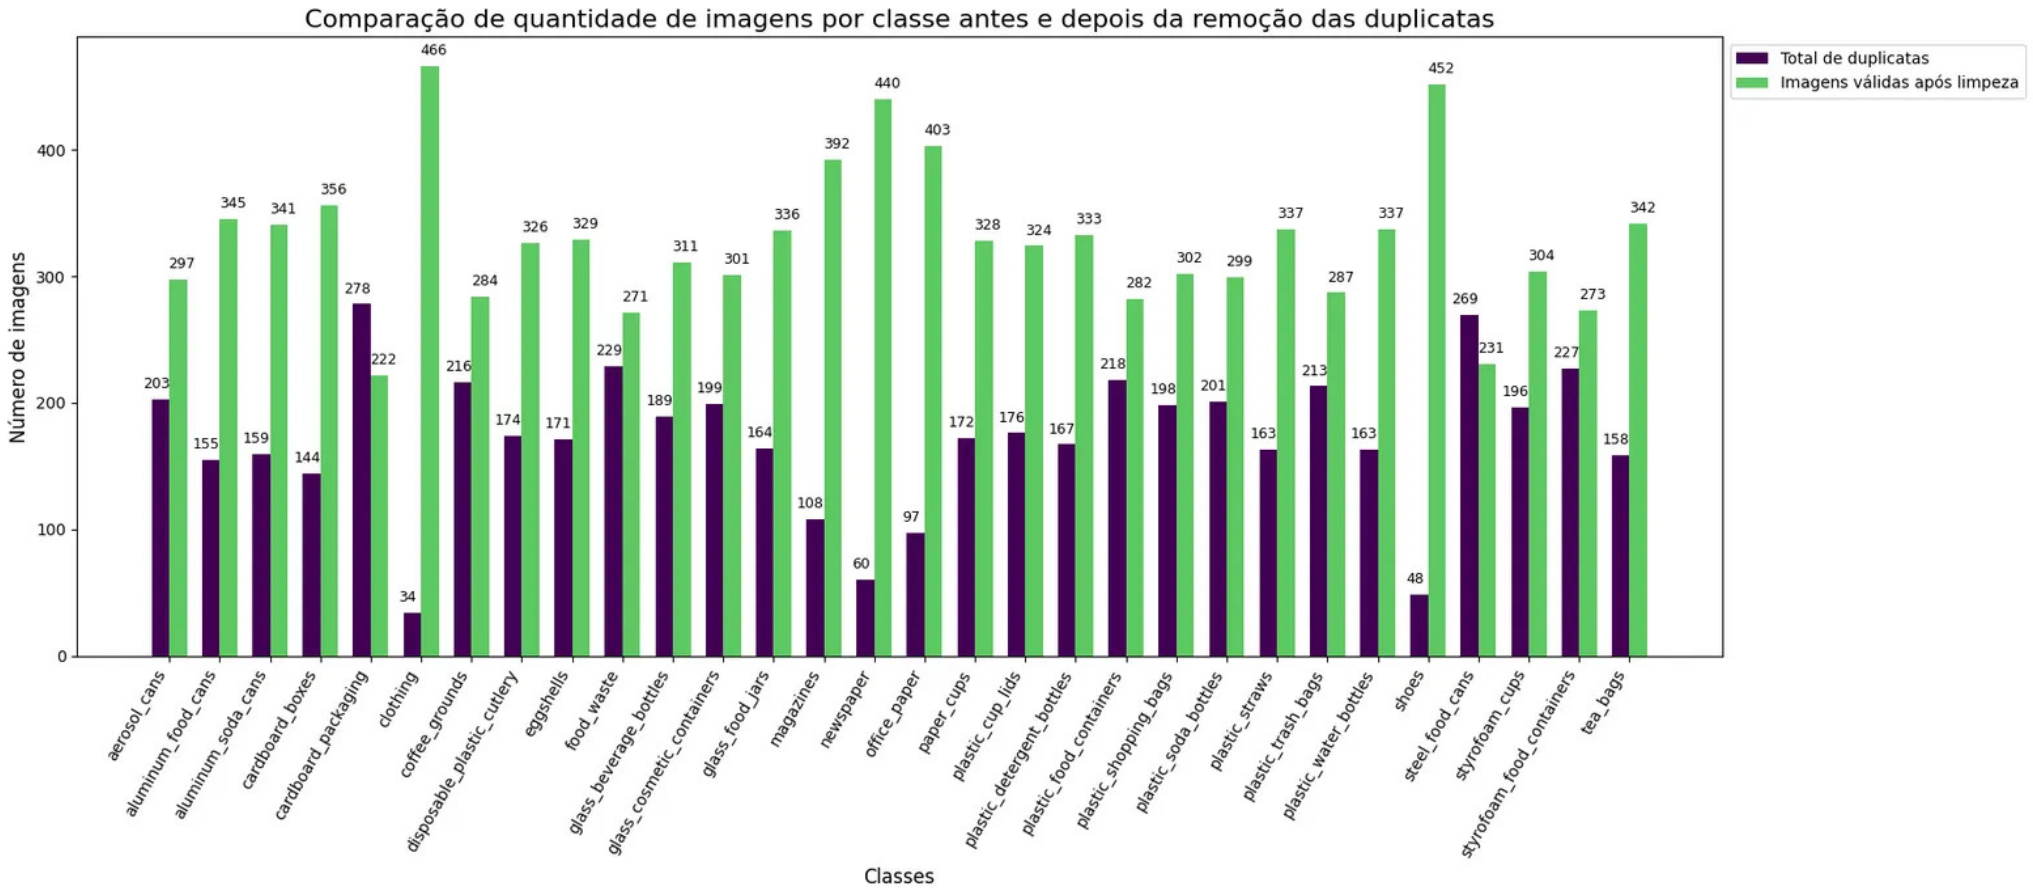

POR QUE NÃO APAGAR TODAS AS DUPLICATAS?

A variação percentual revela quedas críticas de até **-55,6%** em certas classes. A remoção indiscriminada não apenas reduz o volume, mas altera drasticamente a distribuição estatística e a densidade de dados necessária para a generalização do modelo.

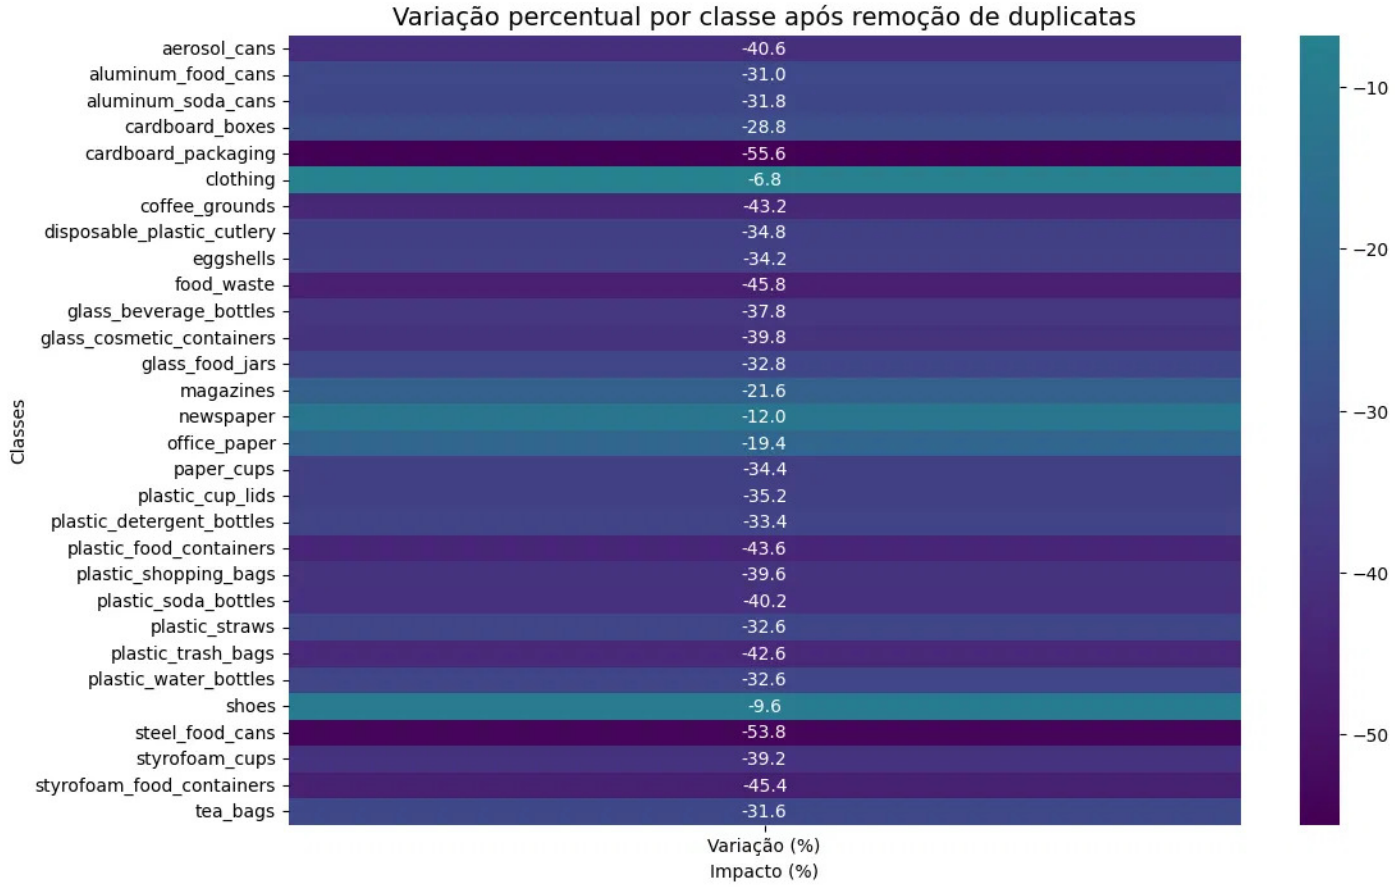

⚙️ ABORDAGEM 1: DEDUPLICAÇÃO CONTROLADA

ESTRATÉGIA

PRÉ-PROCESSAMENTO

Remoção proativa de duplicatas antes da divisão treino/teste para garantir independência.

Método pHash

Identificação de similaridade visual robusta a variações de compressão e ruído.

Balanceamento

Monitoramento rigoroso para manter a representatividade das 30 classes.

VANTAGENS

Independência Estatística

Garante que o modelo não "veja" a mesma amostra em diferentes fases.

Avaliação Confiável

Métricas de teste refletem a capacidade real de generalização.

Simplicidade

Fluxo de trabalho linear e fácil de auditar tecnicamente.

TRADE-OFFS

Redução de Volume

Perda de ~34% do dataset original (5.149 imagens removidas).

Perda de Variabilidade

Variações sutis de iluminação ou ângulo podem ser descartadas como duplicatas.

⚙️ ABORDAGEM 2: GROUP-AWARE SPLIT

Princípios

Tratamento de Grupos: Duplicatas são identificadas como um único grupo correlacionado.

Divisão Consistente: Garante que todos os membros de um grupo fiquem no mesmo conjunto (treino ou teste).

Implementação

Utilização de algoritmos especializados para datasets com dependências espaciais ou temporais.

Ferramentas: `GroupShuffleSplit` e `GroupKFold` da biblioteca Scikit-Learn.

Benefícios Chave

Preservação Total

Utiliza 100% das imagens do dataset, maximizando o volume de dados para o treinamento.

Zero Data Leakage

Previne efetivamente o vazamento de informações, resultando em métricas honestas.

Representatividade

Mantém a variabilidade visual e a distribuição original das classes sem descartar amostras.

📊 COMPARATIVO DAS ABORDAGENS

	DEDUPLICAÇÃO CONTROLADA	GROUP-AWARE SPLIT
Filosofia	Eliminar redundância para garantir independência estatística.	Gerenciar correlação para evitar vazamento de informação.
Impacto no Dataset	Redução do volume de dados (aprox. 34% neste caso).	Preservação de 100% do volume de dados original.
Prevenção de Leakage	Sim, através da remoção física das duplicatas.	Sim, através da alocação consistente de grupos.
Cenário Ideal	Duplicatas exatas que não agregam valor visual.	Amostras correlacionadas ou variações de uma mesma instância.
Vantagens	Avaliação mais "limpa" e independente.	Maximiza o uso de dados; avaliação mais realista.

ESCOLHA DA ABORDAGEM

A decisão depende da natureza do dataset. Em cenários onde a variabilidade visual é importante e as duplicatas representam diferentes "vistas" de um mesmo objeto, o **Group-Aware Split** oferece uma solução mais robusta e representativa.

⚙️ ABORDAGEM 3: DUPLICATAS COMO DOMAIN SHIFT

O Conceito

DOMAIN SHIFT

Diferença de Distribuição

Ocorre quando os dados de treino (Estúdio) diferem visualmente dos dados de teste (Mundo Real).

Duplicatas como "Pontes"

Imagens idênticas em ambientes distintos atuam como âncoras para conectar as duas distribuições estatísticas.

Uso Estratégico

Teste de Robustez

Avaliar intencionalmente se o modelo reconhece o mesmo objeto apesar das mudanças drásticas de iluminação e fundo.

Cenário Realista

Simulação de performance em produção, onde o modelo enfrentará variações não vistas exaustivamente no treino.

Benefícios

- **Avaliação Aprofundada:** Compreensão real da sensibilidade do modelo a mudanças de ambiente.
- **Modelos Adaptáveis:** Incentiva o aprendizado de características invariantes do objeto.
- **Guia para Augmentation:** Direciona a criação de filtros de luz e ruído mais eficazes.

IMPLICAÇÕES E PRÓXIMOS PASSOS

Implicações

Avaliação Realista

Garante que o desempenho reportado seja um reflexo fiel da capacidade do modelo em cenários reais.

Modelos Robustos

O modelo aprende características discriminativas e menos sensíveis a pequenas variações visuais.

Eficiência no Desenvolvimento

Evita o desperdício de recursos em modelos baseados em métricas infladas que falhariam em produção.

Próximos Passos

01 Data Augmentation Sofisticado

Simular variações de iluminação, ruído e oclusão entre ambientes default e real_world.

02 Técnicas de Regularização

Aplicar Dropout, Mixup ou CutMix para mitigar redundância intra-treino e evitar overfitting.

03 Exploração de Domain Adaptation

Investigar algoritmos que alinhem explicitamente as distribuições de diferentes domínios.

04 Análise de Erros Qualitativa

Identificar padrões de falha em imagens duplicadas para guiar melhorias no modelo.

CONCLUSÃO E MENSAGEM FINAL

ESTRATÉGIA DE ENGENHARIA

Group-Aware Split

A solução definitiva para preservar 100% do dataset enquanto elimina o risco de vazamento de informação entre ambientes de estúdio e mundo real.

PRESSUPOSTO FUNDAMENTAL DE ML

> **A melhor prática não é necessariamente remover dados! Mas, sim, garantir a independência estatística para medir a verdadeira capacidade de generalização.**

$$P(\text{train}) \perp P(\text{test})$$

Quando isso falha, métricas deixam de medir generalização.

INSIGHT PROFISSIONAL

"Duplicatas em diferentes contextos são amostras correlacionadas que enriquecem o treinamento, não apenas ruído a ser descartado."

O tratamento ideal combina a divisão baseada em grupos com estratégias conscientes de domínio, garantindo que o modelo aprenda padrões robustos em vez de memorizar exemplos redundantes.